

개인 PC용 개인정보 비식별화 프로그램 기술명세서

I. 기술 개요

1. 시스템 목적


본 시스템은 사용자가 개인 PC에서 문서를 선택하면 문서 내용을 브라우저 내부에서 분석하고, 개인정보 후보를 자동 탐지한 후 사용자 검토를 거쳐 비식별 처리된 결과 파일을 생성하는 단독 실행형 프로그램이다.

2. 핵심 기술원칙

- 가. 모든 처리는 클라이언트 브라우저 안에서 수행한다.
- 나. 외부 서버 및 외부 API를 사용하지 않는다.
- 다. 최종 배포 파일은 하나의 HTML 파일로 구성한다.
- 라. 개인정보 원문과 치환값의 대응정보는 작업 중 메모리에서만 관리한다.
- 마. 작업 종료 후 대응정보를 저장하거나 복구할 수 없도록 한다.
- 바. 비식별 결과는 원칙적으로 복원이 불가능한 결과물로 생성한다.
- 사. 자동 탐지 결과는 사용자가 최종 검토하도록 한다.

II. 시스템 구성

1. 논리 구성



2. 프로그램 모듈

모듈	주요 기능
UI 모듈	파일 선택, 진행상황, 검토화면, 결과화면
파일관리 모듈	파일 읽기, 형식 확인, 크기 검증
문서파서 모듈	파일 형식별 텍스트·표·위치정보 추출
탐지엔진	정규식, 사전, 필드명, 문맥 기반 개인정보 탐지
후보관리 모듈	개인정보 후보 추가·제외·유형변경
비식별 엔진	치환, 마스킹, 삭제 처리
결과생성 모듈	원본 형식 또는 지정 형식으로 파일 재생성
요약정보 모듈	개인정보 유형별 처리건수 산출
메모리관리 모듈	작업 종료 시 임시 데이터 및 대응정보 제거
오류처리 모듈	파일 오류, 분석 실패, 메모리 부족 안내

III. 실행환경

1. 클라이언트 환경

- 운영체제: Windows 10, Windows 11
- 브라우저: 최신 Microsoft Edge, Google Chrome
- 권장 메모리: 16GB 이상
- 권장 CPU: 4코어 이상
- 인터넷 연결: 불필요
- 설치 프로그램: 불필요
- 실행방식: HTML 파일 더블클릭 또는 브라우저에서 열기

2. 배포형태

최종 산출물은 다음과 같이 하나의 파일로 제공한다.

개인정보_비식별화_프로그램_v1.0.html

HTML 파일 내부에 다음 자원을 포함해야 한다.

- HTML 화면구조
- CSS 스타일
- JavaScript 프로그램
- 문서 처리 라이브러리
- 개인정보 탐지 규칙
- 필요한 사전 데이터
- 아이콘 및 이미지

외부 URL을 통해 라이브러리, 글꼴, 모델, 이미지 등을 불러오지 않아야 한다.

IV. 문서 처리 기술명세

1. 공통 처리절차

1. 사용자가 파일을 선택한다.
2. 파일명, 크기, 확장자 및 MIME 유형을 확인한다.
3. 지원 형식 여부를 확인한다.
4. 파일을 ArrayBuffer 또는 텍스트 형태로 브라우저 메모리에 읽는다.
5. 문서 형식에 맞는 파서를 실행한다.
6. 텍스트와 문서 위치정보를 추출한다.
7. 개인정보 탐지엔진에 분석대상을 전달한다.
8. 탐지 결과를 사용자 화면에 표시한다.
9. 사용자의 검토사항을 반영한다.
10. 비식별 처리를 적용한다.
11. 결과 파일을 생성하여 다운로드한다.
12. 작업 완료 후 원문 데이터와 대응정보를 초기화한다.

2. TXT 처리

입력

- UTF-8
- UTF-8 BOM
- EUC-KR 또는 CP949는 가능한 범위에서 지원

처리

- 줄바꿈 구조 유지
- 문자 인코딩 자동 판별
- 텍스트 전체 개인정보 탐지
- 문자열 위치 기반 치환

출력

- 원본 인코딩 또는 UTF-8
- 원본 파일명에 `_비식별` 추가

예:

민원내용.txt
→ 민원내용_비식별.txt

3. CSV 처리

입력 처리

- 쉼표, 탭, 세미콜론 등 구분자 판별

- 첫 행 헤더 여부 확인
- 큰따옴표 및 줄바꿈 포함 셀 처리
- 인코딩 판별

탐지 방식

- 셀 단위 분석
- 헤더명 기반 개인정보 유형 추정
- 열 단위 일괄 처리 지원

예:

성명,전화번호,주소
홍길동,010-1234-5678,부산광역시...

출력

- 원본 구분자 유지
- 셀 구조 유지
- 개인정보가 포함된 셀만 변경

4. XLSX 처리

처리 대상

- 셀 문자열
- 공유 문자열
- 시트별 데이터
- 필요한 경우 주석과 메모

기본 처리원칙

- 가. 시트명과 시트 순서를 유지한다.
- 나. 셀 병합정보를 유지한다.
- 다. 셀 서식을 가능한 범위에서 유지한다.
- 라. 수식은 원칙적으로 변경하지 않는다.
- 마. 개인정보가 수식 결과에만 나타나는 경우에는 사용자에게 제한사항을 안내한다.
- 바. 숨김 시트도 개인정보 검사 대상에 포함할 수 있어야 한다.

주의사항

- 수식 문자열 내부의 개인정보는 별도 정책에 따라 처리한다.
- 외부 연결정보와 매크로는 실행하지 않는다.
- XLSM 파일은 지원 대상에서 제외한다.

5. DOCX 처리

DOCX 파일은 ZIP 컨테이너 내부의 XML 구조를 분석하여 처리한다.

주요 처리대상

- word/document.xml
- 머리글과 바닥글
- 표 내부 텍스트
- 각주 및 미주
- 주석은 정책에 따라 포함

처리원칙

- 문단 및 표 구조 유지
- 텍스트 런이 여러 부분으로 분리된 경우 결합하여 분석
- 치환 후 필요한 경우 텍스트 런 재구성
- 그림과 도형은 변경하지 않음
- 매크로 또는 외부 개체 실행 금지

제한사항

텍스트 길이가 변경되면 줄바꿈이나 문서 배치가 일부 달라질 수 있다.

6. HWPX 처리

HWPX 파일은 ZIP 컨테이너 내부의 XML 파일을 분석한다.

주요 처리대상

- 본문 구역 XML
- 표 내부 텍스트
- 머리말 및 꼬리말
- 메모 또는 주석은 정책에 따라 처리

처리원칙

- 문단 및 표 구조를 최대한 유지
- XML 태그와 속성을 훼손하지 않음
- 개인정보 문자열이 여러 텍스트 노드로 분리된 경우 결합 분석
- 결과 저장 시 유효한 HWPX 구조 유지

제한사항

- 구형 HWP 바이너리 파일은 처리하지 않는다.
- 일부 복잡한 수식, 개체, 배포용 문서에서는 처리가 제한될 수 있다.

7. PDF 처리

지원대상

- 텍스트 레이어가 포함된 일반 PDF

지원 제외

- 스캔 이미지 PDF
- 암호화 PDF

- DRM PDF
- 손상된 PDF
- 복잡한 서명 PDF

권장 처리방식

PDF의 개인정보를 단순히 흰색 사각형으로 가리는 방식은 원문 텍스트가 내부에 남을 수 있으므로 사용하지 않는다.

다음 중 하나의 방법으로 결과를 생성한다.

1. 개인정보가 제거된 텍스트를 기반으로 새 PDF 생성
2. 각 페이지를 이미지로 렌더링한 뒤 개인정보 영역을 불투명 처리하고 새 PDF로 재생성

두 번째 방식은 원문 텍스트 레이어가 남지 않으므로 비식별 효과가 높지만, 검색과 텍스트 복사가 어려워질 수 있다.

PDF 원본 서식을 완전히 유지하면서 텍스트를 안전하게 제거하는 기능은 선택사항으로 분리할 수 있다.

V. 개인정보 탐지엔진 기술명세

1. 탐지방식

개인정보 탐지엔진은 다음 방식을 조합한다.

1. 정규표현식 기반 탐지
2. 형식 유효성 검증
3. 필드명 및 헤더 기반 탐지
4. 앞뒤 문맥 기반 탐지
5. 사전 기반 탐지
6. 사용자 지정 탐지
7. 중복·중첩 후보 정리

2. 개인정보 후보 데이터 구조

```
{
  id: "pii-000001",
  documentPart: "sheet1",
  start: 125,
  end: 138,
  originalText: "010-1234-5678",
  type: "PHONE",
  confidence: 0.98,
  detectionMethod: "REGEX",
  context: "연락처: 010-1234-5678",
  selected: true,
  action: "REPLACE",
  replacementText: "[전화번호_001]"
}
```

`originalText` 값은 작업 중 메모리에서만 유지하며 저장하거나 로그로 출력하지 않는다.

3. 주요 개인정보 유형 코드

코드	유형	기본 치환값
PERSON_NAME	성명	[성명_001]
RRN	주민등록번호	[주민번호_001]
FOREIGNER_NO	외국인등록번호	[외국인번호_001]
PHONE_MOBILE	휴대전화	[휴대전화_001]
PHONE_LANDLINE	일반전화	[전화번호_001]
EMAIL	이메일	[이메일_001]
ADDRESS	주소	[주소_001]
ACCOUNT_NO	계좌번호	[계좌번호_001]
CARD_NO	카드번호	[카드번호_001]
PASSPORT_NO	여권번호	[여권번호_001]
BUSINESS_NO	사업자등록번호	[사업자번호_001]
VEHICLE_NO	차량번호	[차량번호_001]
IP_ADDRESS	IP 주소	[IP주소_001]
BIRTH_DATE	생년월일	[생년월일_001]
CUSTOM	사용자 지정	[개인정보_001]

4. 정규표현식 탐지

각 유형은 정규표현식으로 후보를 찾은 후 유효성 검사를 추가로 수행한다.

주민등록번호

- 하이픈 유무 허용
- 앞 6자리 날짜 유효성 확인
- 뒷자리 첫 숫자 범위 확인
- 필요한 경우 검증번호 확인
- 문서번호 등과의 오탐을 줄이기 위한 문맥 점수 적용

전화번호

- 휴대전화 및 지역번호 분리
- 하이픈, 공백, 괄호 표현 허용
- 숫자 길이 검증
- 문서번호와의 구분을 위한 문맥 확인

이메일

- 아이디, 도메인 및 최상위 도메인 구조 확인
- 문장부호와의 경계 처리

카드번호

- 공백 및 하이픈 표현 허용
- 숫자 길이 확인
- Luhn 검증 적용
- 검증 실패 시 낮은 신뢰도 후보로 표시

사업자등록번호

- 형식 확인
- 검증번호 확인
- 문맥에 따라 개인정보 처리 여부를 사용자가 결정하도록 제공

5. 성명 탐지

성명은 정규표현식만으로 정확하게 판별하기 어려우므로 다음 정보를 조합한다.

- ‘성명’, ‘이름’, ‘신청인’, ‘민원인’, ‘담당자’, ‘소유자’ 등의 앞뒤 값
- 표의 열 제목
- 한국 성씨 사전
- 2~5글자 한글명 형태
- 직위·호칭과 결합된 표현
- 동일 문서 내 반복 출현 여부
- 주소·전화번호 등 다른 개인정보와의 인접성

성명 후보는 신뢰도를 표시하고 사용자 검토를 필수로 한다.

6. 주소 탐지

주소 탐지는 다음 요소를 활용한다.

- 시·도 명칭
- 시·군·구 명칭
- 읍·면·동·리
- 도로명과 번길
- 건물번호
- 아파트명
- 동·호수
- 우편번호
- ‘주소’, ‘소재지’, ‘거주지’ 등의 항목명

주소는 다음 단위로 구분할 수 있어야 한다.

- 전체 주소
- 시·군·구
- 도로명 또는 지번
- 상세주소

- 동·호수

사용자는 전체 주소 또는 상세주소만 선택하여 처리할 수 있어야 한다.

7. 문맥 점수

개인정보 후보의 신뢰도는 다음 요소를 반영하여 산정한다.

최종 신뢰도 =
 형식 일치 점수
 + 유효성 검증 점수
 + 필드명 점수
 + 문맥 점수
 + 반복 출현 점수
 - 오탐 가능성 점수

신뢰도 표시 예시는 다음과 같다.

- 높음: 0.90 이상
- 보통: 0.70 이상 0.90 미만
- 낮음: 0.70 미만

신뢰도 기준값은 환경설정에서 변경할 수 있도록 설계할 수 있다.

8. 중첩 후보 처리

예를 들어 전체 주소 내부에 동·호수 후보가 별도로 탐지될 수 있다.

중첩 후보는 다음 우선순위를 적용한다.

1. 사용자가 직접 지정한 후보
2. 유효성 검증을 통과한 정형정보
3. 더 긴 범위의 개인정보 후보
4. 신뢰도가 높은 후보
5. 필드명과 직접 연결된 후보

중첩된 후보는 사용자에게 병합 또는 개별처리 옵션을 제공한다.

VI. 사용자 검토 기술명세

1. 문서 미리보기

- 개인정보 후보를 유형별 색상으로 표시
- 후보 클릭 시 개인정보 유형과 처리방식 표시
- 현재 선택된 후보 위치로 자동 이동
- 원문과 주변 문맥 표시
- 문서 전체 검색 지원

2. 탐지 목록

탐지 목록은 다음 열을 포함한다.

- 선택 여부
- 순번
- 개인정보 유형
- 탐지 문자열
- 문서 위치
- 신뢰도
- 탐지방식
- 처리방식
- 치환 결과
- 제외 버튼

화면에 개인정보 원문이 표시되더라도 브라우저 저장소나 로그에는 저장하지 않는다.

3. 수동 개인정보 추가

사용자는 다음 방식으로 개인정보를 추가할 수 있다.

- 미리보기에서 문자열 드래그
- 검색결과 일괄 선택
- 셀 또는 열 전체 지정
- 직접 문자열 입력
- 사용자 정규표현식 추가

4. 탐지 제외

탐지 제외는 현재 문서의 현재 작업 세션에만 적용한다. 제외된 개인정보 원문을 별도 학습자료나 사용자 사전으로 자동 저장하지 않는다.

VII. 비식별 처리엔진 기술명세

1. 처리방식

유형별 치환

```
홍길동 → [성명_001]  
010-1234-5678 → [휴대전화_001]  
부산광역시 중구 중앙대로 100 → [주소_001]
```

부분 마스킹

```
홍길동 → 홍**  
010-1234-5678 → 010-****-5678  
example@domain.com → ex*****@domain.com
```

전체 마스킹

홍길동 → ***

삭제

홍길동 → [삭제]

2. 기본 처리정책

개인정보 유형	기본 처리방식
성명	유형별 치환
주민등록번호	전체 마스킹 또는 삭제
외국인등록번호	전체 마스킹 또는 삭제
전화번호	부분 마스킹
이메일	부분 마스킹
주소	유형별 치환
계좌번호	부분 또는 전체 마스킹
카드번호	전체 마스킹
여권번호	전체 마스킹
차량번호	유형별 치환
생년월일	유형별 치환

사용자는 비식별 실행 전 기본 처리정책을 변경할 수 있어야 한다.

3. 동일 값 처리

동일 작업 세션 내에서 동일한 개인정보는 동일한 치환값을 사용한다.

예:

홍길동은 민원인이다.
담당자는 홍길동에게 연락하였다.

↓

[성명_001]은 민원인이다.
담당자는 [성명_001]에게 연락하였다.

이를 위해 다음과 같은 메모리 내 임시 대응구조를 사용할 수 있다.

```
const sessionMapping = new Map();

sessionMapping.set(
  createInternalKey("PERSON_NAME", "홍길동"),
  "[성명_001]"
);
```

해당 Map은 파일로 저장하지 않으며 작업 종료 시 초기화한다.

4. 치환 순서

문자열 위치가 변경되는 문제를 방지하기 위해 다음 방법을 적용한다.

1. 개인정보 후보의 시작·종료 위치 확정
2. 중첩 후보 해결
3. 문서 뒤쪽 위치부터 앞쪽 방향으로 치환
4. 문서구조 재생성
5. 결과 검증

또는 문서 파서가 제공하는 노드 단위 식별자를 사용하여 해당 노드의 텍스트를 직접 수정한다.

5. 복원 방지

본 프로그램은 복원 기능을 제공하지 않으므로 다음 정보를 결과물에 포함하지 않는다.

- 개인정보 원문
- 치환값과 원문의 대응관계
- 원문 해시값
- 암호화된 대응표
- 숨겨진 메타데이터 형태의 원문
- HTML 주석 또는 XML 주석 형태의 원문
- 화면에 표시되지 않는 숨김 데이터

VIII. 데이터 관리 기술명세

1. 메모리 내 데이터

작업 중 다음 정보가 브라우저 메모리에 존재할 수 있다.

- 원본 파일 ArrayBuffer
- 추출 텍스트
- 문서 구조정보
- 개인정보 후보
- 임시 치환 대응정보
- 비식별 처리 결과

2. 저장 금지 데이터

다음 데이터는 브라우저 저장소에 기록하지 않는다.

- 원본 문서
- 추출 텍스트
- 개인정보 후보 원문
- 개인정보와 치환값의 대응정보
- 결과 문서 내용
- 문서 미리보기 캐시
- 사용자 검토 이력

3. 저장 가능한 설정

다음과 같이 개인정보를 포함하지 않는 일반 설정만 선택적으로 저장할 수 있다.

- 기본 처리방식
- 신뢰도 표시 기준
- 화면 확대비율
- 마지막으로 선택한 탭
- 사용자 인터페이스 설정

4. 작업 종료 처리

작업 종료 시 다음 절차를 수행한다.

1. 임시 매핑 Map 초기화
2. 개인정보 후보 배열 초기화
3. 원본 및 결과 ArrayBuffer 참조 해제
4. 생성한 Blob URL 해제
5. Web Worker 종료
6. 미리보기 DOM 제거
7. 파일 입력값 초기화
8. 처리건수만 화면에 남기거나 전체 화면 초기화

JavaScript 가비지 컬렉션의 특성상 물리적 메모리 삭제 시점을 완전히 보장할 수는 없으나, 프로그램이 보유한 모든 참조는 즉시 제거해야 한다.

IX. 결과 파일 기술명세

1. 파일명 규칙

원본파일명_비식별_확장자

동일한 파일명이 존재하는 경우 브라우저의 기본 다운로드 정책을 따른다.

2. 결과 요약정보

화면에는 다음 정보를 제공한다.

- 원본 파일명
- 결과 파일명
- 총 탐지 건수
- 최종 처리 건수
- 탐지 제외 건수
- 수동 추가 건수
- 개인정보 유형별 처리 건수
- 적용된 처리방식별 건수
- 처리 시작·완료 시각
- 프로그램 버전
- 탐지규칙 버전

3. 요약 파일

선택적으로 다음 형식의 요약 파일을 생성할 수 있다.

```
{
  "sourceFileName": "민원목록.xlsx",
  "resultFileName": "민원목록_비식별.xlsx",
  "processedAt": "2026-07-12T10:30:00+09:00",
  "programVersion": "1.0.0",
  "ruleVersion": "1.0.0",
  "detectedCount": 52,
  "processedCount": 49,
  "excludedCount": 6,
  "manuallyAddedCount": 3,
  "typeCounts": {
    "PERSON_NAME": 14,
    "PHONE_MOBILE": 10,
    "ADDRESS": 18,
    "EMAIL": 7
  }
}
```

요약 파일에는 개인정보 원문과 치환값을 포함하지 않는다.

X. 오류처리 기술명세

1. 오류 유형

오류코드	오류내용
E001	지원하지 않는 파일 형식

오류코드	오류내용
E002	파일 크기 초과
E003	파일 읽기 실패
E004	암호 또는 DRM이 적용된 문서
E005	손상된 문서
E006	문서 파싱 실패
E007	브라우저 메모리 부족
E008	결과 파일 생성 실패
E009	지원하지 않는 문서 내부 구조
E010	사용자 작업 취소

2. 오류메시지 원칙

- 가. 개인정보 원문을 오류메시지에 포함하지 않는다.
- 나. 오류 원인을 일반 사용자가 이해할 수 있도록 설명한다.
- 다. 가능한 경우 해결방법을 함께 안내한다.
- 라. 개발자 콘솔에도 문서 본문이나 개인정보를 출력하지 않는다.

예:

파일을 분석할 수 없습니다.
 암호가 설정되었거나 지원하지 않는 문서 구조일 수 있습니다.
 암호를 해제한 복사본을 사용하거나 지원 문서 형식을 확인해 주십시오.

XI. 성능 및 안정성 구현방안

1. 비동기 처리

문서 분석과 개인정보 탐지는 Web Worker를 사용하여 메인 화면과 분리하는 것을 권장한다.

다만 하나의 HTML 파일로 배포하기 위해 Worker 코드를 문자열 또는 Blob으로 생성할 수 있다.

```
const workerBlob = new Blob(
  [embeddedWorkerSource],
  { type: "text/javascript" }
);

const workerUrl = URL.createObjectURL(workerBlob);
const worker = new Worker(workerUrl);
```

작업 완료 후 `URL.revokeObjectURL(workerUrl)` 을 수행한다.

2. 대용량 문서 처리

- 문서를 가능한 범위에서 구간 단위로 분석
- 시트 또는 페이지 단위 진행률 제공
- 개인정보 후보를 일정 단위로 화면에 반영
- 화면 렌더링 시 가상 스크롤 적용
- 대용량 배열 복제를 최소화
- 중복 문자열은 해시 또는 Map으로 관리
- 사용자 취소 요청을 주기적으로 확인

3. 처리 한도

기본 권장값:

- 파일 최대크기: 20MB
- TXT·CSV 최대 행 수: 300,000행
- XLSX 최대 셀 수: 500,000셀
- PDF 최대 페이지 수: 500페이지

실제 한도는 브라우저 및 PC 성능에 따라 조정할 수 있다.

XII. 보안 구현명세

1. 네트워크 차단

프로그램은 다음 기능을 사용하지 않는다.

- `fetch`
- `XMLHttpRequest`
- `WebSocket`
- `EventSource`
- 외부 이미지 URL
- 외부 스크립트 URL
- 외부 CSS URL
- 외부 글꼴 URL
- 외부 분석·통계 도구
- 오류 자동전송 서비스

소스코드 검사 및 브라우저 개발자도구를 통해 외부 통신이 없음을 검증한다.

2. 콘텐츠 보안정책

가능한 경우 HTML 내에 콘텐츠 보안정책을 설정한다.

```
<meta
  http-equiv="Content-Security-Policy"
  content="
```



```
default-src 'self' data: blob;;
connect-src 'none';
img-src 'self' data: blob;;
media-src 'none';
frame-src 'none';
object-src 'none';
"
>
```

단일 HTML에서 인라인 스크립트 사용이 필요한 경우 빌드 방식에 맞춰 정책을 조정해야 한다.

3. 문서 보안

- 문서 내부 링크 자동실행 금지
- 매크로 실행 금지
- XML 외부 엔터티 사용 금지
- ZIP 압축해제 크기 제한
- 비정상적으로 많은 ZIP 항목 제한
- 파일 확장자와 실제 구조 교차검증
- 결과 문서에 원본 메타데이터가 불필요하게 남지 않도록 검토

4. HTML 파일 무결성

배포 시 HTML 파일에 대한 SHA-256 해시값을 별도로 제공하는 것을 권장한다.

```
개인정보_비식별화_프로그램_v1.0.html
개인정보_비식별화_프로그램_v1.0.sha256
```

해시 파일은 프로그램 기능상 암호화와 무관하며, 배포 파일의 변조 여부를 확인하기 위한 용도로 사용한다.

X III. 시험 명세

1. 단위시험

- 파일 형식 판별 시험
- 문자 인코딩 판별 시험
- 주민등록번호 탐지 시험
- 전화번호 탐지 시험
- 이메일 탐지 시험
- 카드번호 유효성 시험
- 주소 탐지 시험
- 동일 값 일관 치환 시험
- 중첩 후보 처리 시험
- 작업 종료 초기화 시험

2. 통합시험

시나리오 1: TXT 처리

1. 개인정보가 포함된 TXT 업로드
2. 자동 탐지
3. 일부 후보 제외
4. 누락 항목 수동 추가
5. 유형별 치환 실행
6. 결과 파일 다운로드
7. 원문 및 대응정보 미포함 확인

시나리오 2: XLSX 처리

1. 다중 시트 XLSX 업로드
2. 숨김 시트 포함 분석
3. 개인정보 열 일괄 선택
4. 전화번호 부분 마스킹
5. 성명 유형별 치환
6. 결과 XLSX 생성
7. 시트명·셀 구조·서식 확인

시나리오 3: DOCX·HWPX 처리

1. 문단과 표가 포함된 문서 업로드
2. 문단 및 표 개인정보 탐지
3. 자동 탐지 결과 수정
4. 결과 문서 생성
5. 문서 열림 여부와 서식 확인

3. 보안시험

- 인터넷 차단 상태 실행
- 외부 통신 발생 여부 점검
- 브라우저 저장소 점검
- 개발자 콘솔 개인정보 출력 여부 점검
- 결과 파일 내부 XML 개인정보 잔존 여부 점검
- 작업 종료 후 재접속 시 이전 작업 복구 여부 점검
- 비정상 압축파일 처리 시험
- 매크로 포함 파일 처리 시험

4. 정확도시험

발주기관 테스트셋을 개인정보 유형별로 구분하여 다음 지표를 산출한다.

정밀도 = 정확하게 탐지한 개인정보 수 / 전체 탐지 수

재현율 = 정확하게 탐지한 개인정보 수 / 실제 개인정보 수

결과보고서에는 다음 내용을 포함한다.

- 개인정보 유형
- 시험 데이터 수
- 실제 개인정보 수
- 탐지 수
- 정탐 수
- 오탐 수
- 누락 수
- 정밀도
- 재현율
- 주요 오탐 사례
- 주요 누락 사례
- 개선 결과

X IV. 소스코드 및 라이브러리 관리

1. 소스코드 기준

- ES6 이상의 표준 JavaScript 사용
- 기능별 클래스 또는 모듈 구조 적용
- 주요 함수에 한글 또는 영문 주석 제공
- 개인정보 원문을 콘솔에 출력하는 디버그 코드 제거
- 예외처리 적용
- 전역변수 사용 최소화
- 상수와 설정값 분리
- 탐지규칙 버전 관리

2. 오픈소스 관리

오픈소스 사용 시 다음 항목을 제출한다.

- 라이브러리명
- 버전
- 사용목적
- 라이선스
- 공식 배포처
- 수정 여부
- 알려진 취약점 점검 결과

외부 라이브러리는 최종 HTML 안에 포함하고 인터넷에서 동적으로 다운로드하지 않는다.

3. 권장 라이브러리 유형

아래는 구현 예시이며 특정 제품 사용을 강제하지 않는다.

- ZIP/XML 처리 라이브러리
- XLSX 처리 라이브러리
- PDF 텍스트 추출·렌더링 라이브러리
- 문자 인코딩 판별 라이브러리

- 파일 저장 보조 라이브러리

라이브러리 선정 시 브라우저 호환성, 라이선스, 파일크기, 유지보수 상태 및 보안성을 검토해야 한다.

X V. 알려진 기술적 제약사항

1. 자동 탐지만으로 모든 개인정보를 100% 식별할 수는 없다.
 2. 성명과 일반명사, 주소와 기관명 등은 오탐이 발생할 수 있다.
 3. 문맥에 의한 간접식별정보는 자동 탐지가 어려울 수 있다.
 4. 구형 HWP는 단일 HTML 프로그램에서 안정적으로 처리하기 어렵다.
 5. 스캔 PDF 및 이미지 문서는 OCR 기능이 없으면 분석할 수 없다.
 6. PDF 원본 서식을 유지하면서 내부 텍스트를 안전하게 제거하는 것은 난도가 높다.
 7. DOCX·HWPX의 텍스트 길이가 변하면 줄바꿈이나 페이지 배치가 달라질 수 있다.
 8. 대용량 문서는 사용자 PC 성능에 따라 처리속도가 달라진다.
 9. 복원용 대응정보를 저장하지 않으므로 비식별 완료 후 원문으로 복원할 수 없다.
 10. 사용자가 원본 문서를 별도로 삭제하지 않는 한 원본 파일의 개인정보는 그대로 남아 있다.
-

X VI. 향후 확장 고려사항

다음 기능은 후속사업으로 검토할 수 있다.

- 비식별 문서 복원 기능
- 대응정보 암호화 저장
- 사용자 인증과 권한관리
- 복원 승인절차
- 한국어 개인정보 인식 AI 모델
- 스캔 PDF 및 이미지 OCR
- 구형 HWP 처리
- 폴더 단위 일괄처리
- 중앙관리형 폐쇄망 시스템
- 처리이력 및 감사로그
- 기관별 개인정보 사전
- 비식별 적정성 자동평가
- 파일 반출 전 개인정보 자동점검